EGFR 화합물 활성 예측 도메인 학습 가이드

분자 구조에서 실험값까지 이해하는 바이오·메디컬 입문

EGFR Evidence Lab | 학습판 1.0 | 2026.10.19

이 가이드는 ChEMBL의 EGFR 데이터를 직접 정제하고 예측 모델을 만들려는 개발자를 위한 학습 자료입니다. 암과 신약개발을 모두 외우기보다, 내가 다루는 한 행의 데이터가 무엇을 측정했는지 설명하는 데 집중합니다.

학습을 마치면 할 수 있어야 하는 일

- 화합물 구조, 표적 단백질, 변이, 실험 조건과 측정값을 구분한다.
- IC50를 올바른 단위로 변환하고 비교할 수 없는 측정을 골라낸다.
- EGFR 억제, 세포 성장 억제, 단백질 분해가 다른 문제임을 설명한다.
- 논문의 근거를 확인하고, 모델 예측과 실제 관측값을 분리해 보고한다.

읽는 순서

범위	내용
02-05	생물학의 기본, 분자 구조, 활성 측정, EGFR 변이
06-08	ChEMBL의 구조, 코호트 정제, 분자 유사도와 평가
09-10	신약개발의 맥락, 문헌 근거를 읽는 방법
11-12	학습 일정, 문제와 해설
13-14	공식 자료·원 논문과 인용 안내

> 프로젝트의 예측 대상은 정의한 실험 조건의 EGFR 활성입니다. 환자의 치료 효과나 TPD 분해 능력은 별도 데이터와 검증이 필요한 문제입니다.

자료 표기는 [1]-[18]이며 마지막 두 페이지에서 제목·링크·사용 목적을 확인할 수 있습니다. 본문의 정제 규칙과 학습 일정은 프로젝트 설계 제안입니다.

01. 유전자에서 표적 단백질까지

EGFR를 이해하기 전에

유전자는 단백질을 만드는 정보를 담고 있습니다. 단백질은 세포 안팎에서 구조를 만들거나 반응과 신호를 조절합니다. 이 프로젝트의 표적은 EGFR라는 단백질이며, 화합물은 그 표적에 작용하는 후보입니다. 유전자 변이와 약물의 화학 구조는 서로 다른 종류의 정보입니다.

EGFR는 epidermal growth factor receptor의 약자입니다. 세포의 분열·생존과 관련된 신호에 관여하는 수용체 티로신 키나아제입니다. EGFR를 억제하는 약물의 연구는 이 신호를 조절하는 접근과 연결됩니다. [1]

대상	예시	데이터에서 확인할 질문
유전자·변이	EGFR, L858R	어떤 서열·변이 상태인가?
표적 단백질	EGFR 단백질	어떤 실험 대상에 작용했는가?
화합물	분자 구조·SMILES	무엇을 투여하거나 반응시켰는가?
실험 반응	효소 활성, 세포 증식	실제로 무엇이 변했는가?

표적을 억제하면 곧바로 암세포가 죽을까?

표적 단백질을 억제하는 현상, 세포 안에서 그 작용이 나타나는 현상, 세포 증식이 줄어드는 현상은 구분해야 합니다. 정제된 단백질과 세포의 실험은 환경이 다릅니다. 같은 IC50라는 이름이어도 어떤 반응을 측정했는지 확인해야 합니다. [2, 5]

> 첫 번째 습관: 화합물 이름과 IC50만 읽지 말고, 표적·변이·실험 종류를 한 문장으로 설명하세요.

연습: "이 화합물은 인간 정상형 EGFR의 단백질 실험에서 억제 활성을 측정했다"와 "이 화합물은 특정 암세포주의 증식을 억제했다"가 왜 다른 데이터인지 설명해 보세요.

출처: [1] NCI EGFR 사전. [2] Assay Guidance Manual. [5] ChEMBL assay/activity 설명.

02. 화합물 구조를 읽는 기초

분자는 원자와 결합의 구조입니다

같은 원소가 포함되어 있어도 원자가 연결된 순서와 공간 배치가 달라지면 다른 분자가 될 수 있습니다. 모델에 분자량 하나만 넣는 것과 분자 구조를 넣는 것은 담고 있는 정보가 다릅니다.

SMILES는 분자 구조를 문자로 표현하는 방식입니다. 예를 들어 에탄올은 CCO로 적을 수 있습니다. 이 예시는 구조 표현을 배우기 위한 것이며 EGFR 활성의 근거가 있는 후보라는 의미는 아닙니다. [4]

표현	읽을 때의 의미	정제에서 주의할 점
C, N, O	원자 종류	대소문자를 임의 변경하지 않기
=, #	이중·삼중 결합	문장 정리처럼 기호를 지우지 않기
괄호·고리 번호	가지·고리 연결	문자열 길이가 분자 크기의 전부는 아님
점(.)	분리된 성분 표현	염·혼합물·다성분 여부 검토
@, @@ 등	입체화학 표현	입체이성질체를 무조건 합치지 않기

SMILES가 다르면 무조건 다른 분자일까?

하나의 분자도 표기 순서에 따라 여러 SMILES를 가질 수 있습니다. RDKit 파싱과 정규화 정책을 적용하고, 원 문자열·처리 문자열·식별자를 모두 보존해야 합니다. 반대로 염이나 입체정보를 지우면서 생기는 정보 손실도 확인해야 합니다. [4]

분자량, 지용성 관련 기술자, 수소결합 특성 등은 구조를 수치화한 특징입니다. 계산된 특징이 실제 실험에서 측정한 값인지도 구분하세요. 계산값으로 학습한 모델과 실험값으로 학습한 모델의 주장 범위는 다릅니다.

> 모델에 넣기 전에 구조 그림을 몇 개 직접 확인하세요. 파싱 성공만으로 생물학적으로 적합한 학습 데이터가 되지는 않습니다.

출처: [4] RDKit 공식 Python 입문. 기호의 세부 문법은 도구 문서와 함께 확인합니다.

03. IC50와 단위를 이해하기

IC50는 정의한 실험 반응을 50% 억제하는 농도입니다. 한 농도에서 억제가 50%였다는 단순 관측과 농도-반응 곡선에서 추정한 IC50를 구분해 읽습니다. 실험의 상·하한과 반응 정의도 확인해야 합니다. [2, 3]

pIC50는 농도의 음의 로그입니다

pIC50 = -log10(IC50 [mol/L])

IC50의 단위가 nM라면 pIC50 = 9 - log10(IC50 [nM])입니다.

IC50	mol/L	pIC50
1 nM	0.000000001	9
10 nM	0.00000001	8
100 nM	0.0000001	7
1 μM = 1000 nM	0.000001	6

비교 가능한 실험에서 낮은 IC50, 높은 pIC50가 더 강한 억제에 해당합니다. pIC50 차이 1은 농도 10배 차이입니다. 그러나 높은 활성이 좋은 약물의 모든 조건을 의미하지는 않습니다.

비슷한 기호를 같은 값으로 합치지 않기

- Ki·Kd는 IC50와 같은 측정값이 아닙니다. 변환에는 추가 가정과 실험 조건이 필요할 수 있습니다. [3]
- >10000 nM는 정확히 10000이 아니라 측정 범위와 관련된 부등호 관측입니다. 첫 회귀 모델의 정확값으로 사용하지 않습니다.
- pChEMBL에는 여러 종류의 활성·친화도 값이 로그 형태로 들어갈 수 있습니다. pChEMBL 열이 있다는 이유만으로 모두 pIC50라고 부르면 안 됩니다. [5]
- ATP·기질 농도 등은 효소 억제 해석에 영향을 줄 수 있습니다. 단위만 같게 맞추면 충분하다고 생각하지 마세요. [2]

출처: [2, 3] Assay Guidance Manual. [5] ChEMBL pChEMBL 정의. 단위 변환 예시는 수학적 계산입니다.

04. EGFR 변이와 내성

변이 표기는 아미노산 변화를 나타냅니다

L858R은 858번 위치의 L이 R로 치환되었다는 표기입니다. T790M과 C797S도 같은 방식으로 읽습니다. 여러 치환이나 결실이 함께 있다면 전체 조합을 보존해야 합니다. 하나의 변이명만 떼어 읽으면 실험 대상을 잘못 묶을 수 있습니다.

구분	의미	이 프로젝트의 처리
정상형(WT)	기준이 되는 변이가 없는 상태	메타데이터·실험 설명 검토
명시적 변이	어떤 서열 변화인지 확인 가능	변이별 코호트로 분리
복합 변이	변화가 둘 이상 함께 존재	조합 전체와 맥락 보존
불명확	정보가 없거나 충돌함	정상형으로 추정하지 않고 보류

내성은 약물과 실험 맥락을 포함합니다

내성은 특정 약물에 대한 반응이 줄어드는 문제입니다. 변이가 있다는 사실 자체를 내성이라고 부를 수는 없습니다. Thress 등의 원 연구는 EGFR C797S와 AZD9291에 대한 획득 내성을 다뤘습니다. 이는 구체적인 약물·변이·실험 맥락의 근거입니다. [7]

이 프로젝트에서는 변이별 표본과 실험 조건을 확인한 뒤 학습 범위를 정합니다. 정상형 모델이 잘 작동한다고 해서 복합 변이에도 잘 작동한다고 주장하지 않습니다.

> ChEMBL에서는 정상형과 변이형이 같은 target ID를 사용할 수 있습니다. CHEMBL203으로 조회했다는 것만으로 정상형 자료가 되는 것은 아닙니다. [6]

연습: 같은 화합물의 WT 단백질 IC50와 변이 세포주의 증식 IC50가 다를 때, 그 차이를 곧바로 변이 효과라고 결론 내릴 수 있을까요? 실험 형식과 조건이 함께 달라졌는지 먼저 확인해야 합니다.

출처: [6] ChEMBL target FAQ. [7] Thress et al., Nature Medicine 2015.

05. ChEMBL의 한 행을 해석하기

ChEMBL은 화합물·표적·실험·활성·문헌을 연결하는 데이터베이스입니다. 같은 분자가 여러 실험에 등장하고, 하나의 문헌에 여러 측정이 있을 수 있습니다. 표의 행 수와 서로 다른 화합물 수를 구분하는 것이 출발점입니다. [5, 8]

구성	확인할 정보	왜 필요한가?
Molecule	분자 ID·SMILES	어떤 화합물인지 확인
Target	표적 ID·생물종	어떤 생물학적 대상인지 확인
Assay	실험 유형·설명·변이	측정 맥락과 비교 가능성 확인
Activity	유형·값·단위·부등호	목표값을 정확히 구성
Document	문헌 ID·DOI·PMID 등	원 근거와 처리 과정을 추적

수집 후 꼭 기록할 것

- ChEMBL release, 수집 시각, 요청 조건과 원 파일의 해시.
- 원자료 행 수, 서로 다른 분자 수, 실험 수와 문헌 수.
- 단위·변이·실험 형식·중복·결측치의 분포.
- 어떤 행을 왜 제외했고, 정제 후 무엇이 남았는지.

ChEMBL의 신뢰도 점수는 assay와 target의 연결에 관한 정보입니다. 높은 점수만으로 ATP 조건, 세포 환경, 변이 상태가 같다고 보장하지 않습니다. 품질·잠재적 중복 플래그도 확인하되, 표시의 의미와 원문을 검토합니다. [5]

공식 DB는 변이 구분에 variant 정보를 사용합니다. 자동 분류 결과와 실험 설명을 함께 검토하고, 불분명한 사례는 검토 상태를 남기는 보수적인 방식을 권장합니다. [6]

> 좋은 데이터 정제는 행을 많이 남기는 작업이 아닙니다. 무엇을 예측하게 되었는지 설명할 수 있게 만드는 작업입니다.

출처: [5, 6, 8] ChEMBL 공식 문서. 기록 항목과 보류 정책은 프로젝트 설계 제안입니다.

06. 학습 코호트를 만드는 연습

코호트는 이번 모델에서 함께 다루기로 정한 데이터 집합입니다. 처음에는 인간 EGFR, 한 엔드포인트, 비교 가능한 실험 형식, 해석 가능한 한 변이 상태로 범위를 좁히는 것을 제안합니다.

가상의 네 행을 분류해 보기

아래는 원칙을 설명하려고 만든 예시이며 ChEMBL에서 추출한 실제 측정값이 아닙니다.

행	기록	첫 모델의 판단 예시
A	WT 단백질, IC50 = 10 nM	실험 조건을 검토한 뒤 포함 후보
B	WT 단백질, IC50 > 10000 nM	정확값 회귀에서는 제외·보존
C	변이 세포주, 증식 IC50 = 10 nM	A와 분리; 다른 코호트 후보
D	WT 단백질, Kd = 10 nM	IC50 목표값과 분리

반복 측정을 어떻게 처리할까?

같은 분자가 여러 번 등장했다고 모두 중복 오류는 아닙니다. 독립 반복, 다른 실험 조건, 다른 변이 또는 이미 보고된 측정의 재인용일 수 있습니다. 같은 분자·비교 가능한 실험 맥락에서만 요약 여부를 결정하고 원 행과 연결을 남깁니다. [3, 5]

다른 문헌의 측정값을 무조건 평균내면 표적·변이·조건의 차이가 가려질 수 있습니다. 값이 크게 다른 사례는 먼저 라벨을 버리기보다 맥락을 확인하는 검토 대상으로 표시하세요.

검토표에 쓸 한 문장

"A는 단위와 실험 대상을 확인해 포함 후보로 두었다. B는 부등호가 있어 정확값 학습에서 제외했다. C와 D는 별도 엔드포인트·코호트로 분리했다."

> 포함/제외 규칙은 모델 성능을 본 뒤 유리하게 바꾸지 말고, 데이터 감사와 생물학적 정의를 바탕으로 먼저 정하세요.

출처: [3, 5, 6] 실험 결과 정의·활성·변이 문서. 네 행과 처리 순서는 교육용 설계 예시입니다.

07. 분자 유사도와 평가의 함정

fingerprint와 scaffold의 역할

Morgan fingerprint는 분자의 국소 구조를 수치 표현으로 바꾸는 방식입니다. 이를 입력으로 Random Forest 같은 모델을 학습하거나 분자 유사도를 계산할 수 있습니다. Scaffold는 핵심 골격을 기준으로 구조를 묶는 데 사용합니다. [4, 9]

분자가 매우 비슷하면 학습 데이터와 테스트 데이터가 서로 독립적인 새로운 화학 구조를 대표하지 못할 수 있습니다. 같은 분자의 반복 측정이 양쪽에 들어가는 경우도 막아야 합니다.

평가 방식	답하려는 질문	한계
분자별 random 분할	같은 자료 분포의 화합물에서 어떤가?	유사 골격이 양쪽에 남을 수 있음
scaffold 분할	보지 못한 골격에서 어떤가?	모든 구조 차이나 실험 차이를 보장하지 않음
문헌·실험 holdout	다른 보고 맥락에서 어떤가?	분자 중복과 표본 감소를 별도로 점검

지표를 생물학적 주장으로 과장하지 않기

- MAE는 pIC50 예측의 평균 절대 오차입니다. 어떤 코호트와 분할의 결과인지 함께 적습니다.
- RMSE는 큰 오차의 영향을 더 받습니다. 큰 오차가 난 실험·구조를 살펴보세요.
- Spearman은 순위의 관련성을 봅니다. 농도값 자체가 정확하다는 뜻은 아닙니다.
- 유사도는 적용 범위를 살피는 참고치이며 예측이 맞을 확률은 아닙니다.

Scaffold 평가의 연구 근거는 Yang 등의 논문에서 읽을 수 있습니다. [9] 교차검증과 최종 테스트의 역할은 별도로 구분하고, 모델 선택은 학습·검증 자료에서 수행합니다. [10]

> 정상형 실험에서 높은 평가 점수를 얻었다는 결과를 변이·세포·환자·신약 성공률로 확대하지 않는 것이 연구의 기본입니다.

출처: [4] RDKit. [9] Yang et al., 2019. [10] scikit-learn 평가 문서. 분할 조합은 프로젝트 설계입니다.

08. 신약개발 안에서의 위치

표적 활성이 좋아도 체내에서 필요한 곳에 도달하고, 충분히 유지되며, 안전해야 약물로 개발할 가능성을 검토할 수 있습니다. 이번 프로젝트는 그중 공개 실험의 표적 활성 예측에 초점을 맞춥니다.

개념	공부할 핵심	이번 모델과의 관계
ADME	흡수·분포·대사·배설	별도의 측정값과 예측 과제
PK	시간에 따른 농도·노출 등 체내 거동	IC50만으로 결정할 수 없음
독성·선택성	원치 않는 작용과 다른 표적 영향	EGFR 활성과 따로 평가
ADC	항체와 약물을 연결하는 접근	항체·링커·페이로드 정보도 필요
TPD·PROTAC	표적 단백질 분해 유도	분해 실험과 맥락이 필요

ADME의 데이터 과제는 TDC 설명에서 확인할 수 있습니다. [11] ADC의 기본 정의는 NCI 사전에서 읽습니다. [12] PROTAC은 표적 단백질 분해를 유도하는 접근 중 하나이며, 분해·결합·세포 활성을 구분한 자료를 확인해야 합니다. [13]

IC50와 DC50·Dmax는 다릅니다

PROTAC-DB는 분해 능력을 DC50·Dmax 등으로 기록하며, 표적·E3 ligase와의 결합이나 세포 활성도 별도로 다룹니다. EGFR 억제 IC50를 학습한 모델을 단백질 분해 효능 모델이라고 부르면 예측 대상을 바꾸어 말하는 셈입니다. [13]

회사의 공개 공고는 AI 신약설계와 ADC/DAC/TPD, PK/DMPK 업무를 언급합니다. 이 맥락을 이해하되 회사의 비공개 실험이나 실제 내부 스택을 재현했다고 주장하지 않습니다. [14]

> 현재 프로젝트의 정확한 소개: "공개 EGFR 실험 자료를 정제하고 화합물 활성을 예측하며, 관련 문헌 근거를 추적하는 연구 도구."

출처: [11-14] TDC, NCI, PROTAC-DB, 회사 게시 공고. 약물 개발 성과는 현재 검증 대상이 아닙니다.

09. 논문을 근거로 읽는 방법

초록 다음에는 Methods와 실험 조건을 읽기

논문에 EGFR와 화합물명이 함께 등장하는 것만으로 특정 활성값을 뒷받침하지는 않습니다. 표적·변이·실험 형식·단위·조건이 일치하는 문장이나 표를 찾아야 합니다. 데이터베이스의 연결된 원문을 출발점으로 사용하세요.

읽을 항목	기록할 질문
실험 대상	정상형인가, 어떤 변이 조합인가?
실험 방법	분리된 단백질인가, 어떤 세포주인가?
엔드포인트	표적 억제인가, 증식 억제인가, 분해인가?
수치와 조건	농도 단위·처리 시간·반복 측정이 무엇인가?
비교 대상	같은 조건에서 비교했는가?
근거 위치	문헌 ID, 표·그림·문단을 다시 찾을 수 있는가?

예측·관측·문헌 설명을 분리하기

- 관측: 데이터베이스나 원 논문에서 확인한 실험값. 출처와 조건을 붙입니다.
- 예측: 학습된 모델이 계산한 값. 모델 버전·대상 코호트·적용 범위를 붙입니다.
- 문헌 설명: 근거를 읽어 요약한 문장. 인용한 위치가 주장을 지지하는지 확인합니다.

RAG는 찾아온 문서를 바탕으로 답변을 만드는 방식입니다. Agent는 요청과 중간 결과에 따라 예측·조회·검색 도구를 선택하도록 확장할 수 있습니다. 단순한 고정 검색 순서와 동적인 도구 선택은 구분합니다. [15, 16]

> 관련 논문이 검색되었다는 사실은 모델의 새 예측값을 실험으로 입증한 것이 아닙니다. 근거가 없으면 정보 부족으로 남겨야 합니다.

문헌 원문은 공개적으로 보이는 것과 재사용 허용 범위가 다를 수 있습니다. 제공 API와 논문별 이용 조건을 확인하며 문헌 인덱스를 만듭니다. [15, 17]

출처: [15] Europe PMC. [16] LangGraph. [17] PMC 개발자 정책. 체크리스트는 프로젝트 검토 절차 제안입니다.

10. 공부와 구현을 연결하는 일정

아래는 하루 60-90분 학습을 가정한 2주 입문 제안입니다. 익숙하지 않은 단원은 구현 전에 반복하세요. 전체 프로젝트 완료 일정이나 모델 성능을 보장하는 일정은 아닙니다.

기간	학습·실습	남길 산출물
1-2일	EGFR·표적·화합물·실험 구분	한 행을 설명하는 문장 5개
3-4일	SMILES·염·입체화학·구조 표현	파싱·구조 검토 노트
5-6일	IC50·pIC50·단위·부등호	단위 변환과 예외 처리
7-8일	변이·정상형·실험 코호트	assay 검토표·제외 기준
9-10일	ChEMBL 관계·중복·출처	데이터 감사 보고서
11-12일	유사도·scaffold·평가	분할 정책과 누수 점검표
13-14일	원 논문 읽기·근거 추적	문헌 카드 3개와 발표 요약

문헌 카드 양식

논문 제목·DOI/PMID / 연구 질문 / 표적·변이 / 화합물 / 실험 형식 / 엔드포인트·단위 / 조건·반복 / 주요 결과 / 근거 위치 / 우리 데이터에 포함할지와 이유.

구현 단계에 들어갈 준비가 되었는가?

- 10 nM와 10 μM의 차이와 pIC50를 계산할 수 있다.
- 같은 표적 ID여도 실험을 섞으면 안 되는 이유를 설명한다.
- 부등호·미상 변이·상충 측정의 처리 근거를 쓸 수 있다.
- 모델 평가 점수와 약물 개발 성과가 다른 주장임을 설명한다.
- 논문 방법의 적용과 원 성능 재현의 차이를 설명한다.

마지막 항목의 읽기 자료로 Chemprop 논문을 사용합니다. EGFR에 적용하는 신규 실험과 저자의 공개 벤치마크 재현을 구분해 기록하세요. [18]

출처: 학습 순서·시간은 제안입니다. [18] Chemprop 원 논문과 저자 benchmark 자료.

11. 확인 문제와 해설

먼저 답한 뒤 해설을 읽으세요

Q1. 10 nM의 pIC50는? 1 μM는?

각각 8과 6입니다. nM를 mol/L로 환산하고 음의 로그를 취합니다. 단위를 생략하면 큰 라벨 오류가 생깁니다.

Q2. pChEMBL 값이 있는 모든 행을 pIC50 학습에 넣어도 될까요?

아닙니다. 원 측정 유형과 단위·부등호를 확인해 IC50를 선별합니다. 다른 엔드포인트가 포함될 수 있습니다. [5]

Q3. target ID가 같고 값도 10 nM인 두 행은 같은 실험일까요?

아닙니다. 변이, assay 형식, 실험 조건과 문헌을 확인해야 합니다. 정상형과 변이형이 같은 표적 ID일 수도 있습니다. [6]

Q4. IC50 > 10000 nM를 10000이라는 정답으로 바꾸어도 될까요?

정확값 회귀에서는 안 됩니다. 부등호 관측으로 별도 보존하고, 이후 필요하면 그에 맞는 모델링 방법을 검토합니다.

Q5. WT 효소 실험과 변이 세포주의 결과 차이가 곧 변이 효과일까요?

그렇게 단정할 수 없습니다. 변이뿐 아니라 실험 형식과 조건도 바뀌었기 때문입니다. 비교 가능한 맥락이 필요합니다.

Q6. EGFR IC50를 잘 맞추면 TPD나 환자 효과도 예측한 것일까요?

아닙니다. 분해 지표와 임상 결과는 다른 예측 대상입니다. 관련 데이터와 별도 검증을 요구합니다. [13]

Q7. 검색된 관련 논문이 새 화합물의 예측을 입증할까요?

아닙니다. 논문에 그 화합물의 해당 실험값이 있는지 확인하고, 유사 화합물의 자료라면 참고 근거로 구분합니다.

Q8. 딥러닝 모델을 실행하면 논문을 재현한 것일까요?

새 EGFR 자료에 적용한 것은 방법 적용입니다. 원 데이터·분할·코드·설정·지표를 맞추고 결과를 비교해야 해당 실험의 재현이라고 설명할 수 있습니다. [18]

출처: [5, 6, 13, 18]. 수학 문제와 판단 연습은 이 프로젝트의 교육용 구성입니다.

참고문헌 1. 바이오·실험·데이터

[1] NCI. Definition of EGFR. 수용체·세포 신호의 기본 정의. 공식 페이지

[2] Assay Guidance Manual. Basics of Enzymatic Assays for HTS / Assay Development for Protein Kinase Enzymes. 효소 IC50·ATP·실험 조건. 효소 실험 / 키나아제 실험

[3] Assay Guidance Manual. Data Standardization for Results Management. IC50·Ki·집계와 실험값 정의. 원문

[4] RDKit. Getting Started in Python. SMILES 처리·분자 구조·Morgan fingerprint·유사도. 공식 문서

[5] ChEMBL. Assay and Activity Questions. 실험 유형·pChEMBL·품질·잠재 중복. 공식 문서

[6] ChEMBL. Target Questions. 정상형·변이형의 표적 ID와 variant 정보. 공식 문서

[7] Thress et al. Nature Medicine, 2015;21:560-562. Acquired EGFR C797S mutation mediates resistance to AZD9291 in non-small cell lung cancer harboring EGFR T790M. DOI:10.1038/nm.3854. PubMed PMID:25939061

[8] ChEMBL. Schema Questions and SQL Examples. 분자·실험·활성·표적을 연결하는 구조를 확인하는 자료. 공식 문서

[9] Yang et al. JCIM, 2019. Analyzing Learned Molecular Representations for Property Prediction. DOI:10.1021/acs.jcim.9b00237. 저자 소속기관 공개 PDF

참고문헌의 설명은 자료를 찾기 위한 요약입니다. 특정 약물의 효과·승인 상태나 최신 치료 지침을 제공하는 목록은 아닙니다.

참고문헌 2. 개발 맥락·문헌 활용

[10] scikit-learn. Cross-validation: evaluating estimator performance. 학습·검증·테스트와 그룹 분할. 공식 문서

[11] Therapeutics Data Commons. ADME Property Prediction. 흡수·분포·대사·배설의 예측 과제. 공식 설명

[12] NCI. Definition of antibody-drug conjugate. ADC 기본 개념. 공식 사전

[13] PROTAC-DB. About / PROTAC-DB 3.0. 분해 능력·결합·세포 활성의 구분. DOI:10.1093/nar/gkae768. 공식 설명 / 원 논문

[14] 비엔제이바이오파마 회사 게시 신약개발 연구원 공고. ADC/DAC/TPD, PK/DMPK 업무 맥락. 원 공고

[15] Europe PMC. Developer resources. 문헌 메타데이터와 허용된 텍스트의 API 접근. 공식 안내

[16] LangGraph. Workflows and agents. 고정 흐름과 도구 선택의 구분. 공식 문서

[17] PMC. For Developers. 자동 수집 서비스와 논문별 이용 조건. 공식 정책

[18] Heid et al. JCIM, 2024;64:9-17. Chemprop: A Machine Learning Package for Chemical Property Prediction. DOI:10.1021/acs.jcim.3c01250. 원 논문 / 저자 benchmark

자료와 재현에 관한 메모

자료 확인 기준일은 2026.10.19입니다. 학습 내용과 프로젝트 제안은 원 연구의 검증 범위와 구분합니다. 원자료 수집 시 ChEMBL release·출처·파일 해시·가공 규칙을 기록하고, 논문 본문은 재사용 조건을 확인합니다.

이 문서는 자체 작성한 입문 요약입니다. 출처 원문을 대체하지 않으며, 실험 결과나 모델 성능을 새로 입증한 자료가 아닙니다.