EGFR Evidence Lab 학습 가이드

이 프로젝트를 하면서 실제로 마주친 의학·메디컬 도메인 지식과 AI 기술을 정리했습니다. 교과서 요약이 아니라 이 프로젝트의 어느 지점에서 그 지식이 필요했는지를 함께 적었습니다. 외워야 할 목록이 아니라, 판단이 필요했던 자리의 기록입니다.

수치는 전부 이 프로젝트의 실제 산출물에서 가져왔습니다. 추정이나 예시가 아닙니다.

1부. 의학·메디컬 도메인 지식

1.1 EGFR이 무엇이고 왜 이 표적인가

EGFR(Epidermal Growth Factor Receptor, 상피성장인자 수용체)은 세포막을 관통하는 수용체 티로신 키나아제입니다. 세포 밖에서 성장인자가 붙으면 세포 안쪽의 키나아제 영역이 활성화되고, 그 신호가 세포 증식으로 이어집니다.

이 수용체에 돌연변이가 생겨 신호가 꺼지지 않으면 세포가 계속 증식합니다. 비소세포폐암(NSCLC)의 일부가 이 경로에 의존하며, 그래서 EGFR 키나아제를 막는 약이 치료제로 쓰입니다.

이 프로젝트에서: ChEMBL의 표적 ID CHEMBL203이 인간 EGFR입니다. 여기에 연결된 IC50 측정 26,600건, 분자 14,776개, 실험(assay) 2,425개, 문헌 1,299편을 수집했습니다.

1.2 활성 지표 — IC50, Ki, Kd, pIC50

지표	뜻	성격
IC50	활성을 50% 억제하는 농도	실험 조건에 따라 변한다
Ki	억제 상수(결합 친화도)	기질 농도를 보정한 값
Kd	해리 상수	결합만 본 값, 억제가 아님
EC50	50% 효과를 내는 농도	작용제·길항제 모두
GI50	세포 성장을 50% 억제하는 농도	세포 수준

IC50은 작을수록 강한 저해제입니다. 농도 단위(nM)라 값이 커질수록 약한 쪽이어서 직관과 반대입니다. 그래서 로그로 변환합니다.

`

pIC50 = -log10(IC50 〔M〕) = 9 - log10(IC50 〔nM〕)

`

IC50 10 nM이면 pIC50 = 8입니다. pIC50은 클수록 강한 저해제이고, 분포가 정규에 가까워져 회귀에 쓰기 좋습니다.

섞으면 안 되는 이유: IC50과 Ki는 정의가 다릅니다. Ki는 Cheng-Prusoff 식으로 IC50에서 환산할 수 있지만 기질 농도와 Km을 알아야 하고, 논문에 그 값이 없으면 환산이 불가능합니다. 이 프로젝트는 IC50만 다루고 Ki·Kd와 합치지 않았습니다(configs/project.json의 pool_ic50_ki_kd: false).

1.3 생화학 실험과 세포 실험은 다른 양이다

같은 "IC50"이라도 무엇을 측정했는지가 다릅니다.

구분	측정 대상	영향 요인
생화학(biochemical)	정제한 효소의 활성 억제	효소·ATP·기질 농도, 완충액
세포(cell-based)	살아 있는 세포의 반응	세포막 투과성, 유출 펌프, 대사, 혈청 단백 결합

세포 실험 IC50은 보통 생화학보다 큽니다. 약이 세포 안까지 들어가야 하기 때문입니다. 두 값을 한 라벨로 합치면 모델이 "화합물의 저해 능력"이 아니라 "저해 능력 + 투과성의 뒤섞임"을 배웁니다.

이 프로젝트에서: ChEMBL의 assay_type으로 구분했습니다. 수집한 2,425개 assay 중 생화학(B) 2,264개, 기능(F) 104개, ADME(A) 55개, 독성(T) 2개였습니다. bao_label로 측정 형식을 더 좁혀 단일 단백질 형식 1,509개 / 세포 기반 606개를 구분했습니다. 학습에는 생화학 + 단일 단백질 형식만 썼습니다.

1.4 변이 — 내성의 진화를 읽는 법

EGFR 저해제의 역사는 내성 변이와의 경쟁입니다.

변이	위치·성격	임상적 의미
L858R	exon 21, 활성화 변이	1세대 저해제(gefitinib, erlotinib)가 잘 듣는다
exon 19 deletion	활성화 변이	1세대 감수성
T790M	gatekeeper 위치	1세대 내성. 3세대(osimertinib)가 표적
C797S	공유결합 부위의 시스테인 소실	3세대 내성. 공유결합 자체가 불가능해진다
L861Q, G719X	비전형 활성화 변이	반응이 변이마다 다르다
exon 20 insertion	입체 구조 변화	전통적 저해제에 잘 듣지 않는다

C797S가 특히 중요합니다. 3세대 저해제는 C797 잔기에 공유결합해서 작동하는데, 그 시스테인이 세린으로 바뀌면 결합할 대상 자체가 없어집니다. 그래서 4세대 저해제나 분해제(degrader) 전략이 연구됩니다.

이 프로젝트에서: 수집한 assay 2,425개 중 616개에 변이가 표기돼 있었고 표기는 12종이었습니다.

변이 표기	assay 수
L858R, T790M	203
L858R	116
UNDEFINED MUTATION	115
L858R, T790M, C797S	90
T790M	70
L861Q	9
T790M, C797S	5
C797S / C797S,L858R / G719C	각 2
T790M,L858M / G719S	각 1

이 분포는 ChEMBL assay의 변이 표기이며 임상 빈도가 아닙니다. 연구가 많이 된 변이가 많이 나타납니다.

UNDEFINED MUTATION 115건이 중요한 함정입니다. 변이가 있다고만 적혀 있고 무엇인지 모릅니다. 정상형으로도, 특정 변이로도 쓸 수 없습니다. 이 프로젝트는 unknown_variant_is_wild_type: false로 고정했습니다 — 모르는 것을 정상형으로 가정하지 않는다는 뜻입니다.

1.5 부등호 관측 — 〉10000 nM은 측정값이 아니다

ChEMBL의 standard_relation에는 등식 외에 부등호가 들어옵니다.

관계	측정 건수	뜻
=	19,719	값을 측정했다
〉	3,309	그 농도까지 올려도 50% 억제가 안 됐다
〈	2,067	가장 낮은 시험 농도에서도 이미 억제됐다
〈=	87	상한
〉〉	11	훨씬 크다
〉=	8	하한

〉10000 nM을 10000으로 적어 회귀에 넣으면 그 화합물이 10 μM에서 정확히 반 억제된다고 가르치는 것입니다. 사실은 "10 μM까지는 효과가 없었다"입니다. 실제 값은 10 μM보다 크고, 얼마나 큰지 모릅니다.

이것은 통계학에서 중도절단(censored) 데이터입니다. 제대로 다루려면 생존분석류의 방법이 필요하고, 단순 회귀로는 처리할 수 없습니다.

이 프로젝트에서: 등식만 남겼습니다. 26,600건에서 19,719건으로 줄었습니다. 부등호 관측 5,482건을 버린 것이 아니라 별도로 보존했습니다 — 분류 문제로 쓸 수 있는 자료입니다.

1.6 실험 조건 — 같은 IC50이 왜 다른 양인가

생화학 IC50을 결정하는 조건들입니다.

조건	왜 중요한가
효소 농도	너무 높으면 저해제가 소진돼 IC50이 과대평가된다
ATP 농도	ATP 경쟁 저해제는 ATP가 많을수록 IC50이 커진다
기질 종류·농도	펩타이드 기질마다 Km이 다르다
전처리(preincubation) 시간	느린 결합 저해제·공유결합 저해제에 결정적이다
반응 시간	공유결합 저해제는 시간이 길수록 강해 보인다
온도·pH	효소 활성과 화합물 안정성에 영향
검출 방식	방사성, 형광, 발광 — 간섭 양상이 다르다
효소 구조체	키나아제 영역만 vs 전장 단백질

ATP 경쟁 저해제의 IC50은 ATP 농도에 따라 몇 배씩 달라집니다. 어떤 논문은 1 μM ATP, 어떤 논문은 10 μM ATP를 쓰는데, 같은 화합물이 다른 IC50으로 보고됩니다. 조건을 모르면 두 값을 비교할 수 없습니다.

이 프로젝트에서: configs/cohort_policy.json에 13개 필수 필드를 정의했습니다 — species, variant, protein_construct, enzyme_concentration, atp_uM, substrate, substrate_concentration, preincubation_minutes, reaction_minutes, temperature_C, buffer_pH, readout, inhibitor_scope. 값이 빠진 것을 같다고 보지 않는다

(missing_values_count_as_equal: false)고 못박았습니다.

결과적으로 cross-assay pooling 승인 0쌍이 됐습니다. 선정 기준을 모두 통과한 측정이 5,511건·assay 558개나 남았는데, 조건이 같다고 원문으로 확인한 조합이 하나도 없어 단일 assay 22건만 학습에 썼습니다. 이것이 이 프로젝트의 가장 큰 제약이고, 동시에 가장 정직한 선택입니다.

1.7 ChEMBL 데이터 구조

테이블	내용	이 프로젝트의 규모
activities	측정 한 건	26,600행 × 32열
assays	실험 조건	2,425행 × 19열
molecules	분자 구조	14,776행 × 6열
documents	문헌 서지	1,299행 × 8열

추적 체인은 이렇게 이어집니다.

`

분자(molecule_chembl_id) → 측정(activity_id) → 실험(assay_chembl_id) → 문헌(document_chembl_id → DOI)

`

activity_id를 알면 ChEMBL 원본 한 건까지 되짚을 수 있습니다. 이 연결이 "근거 추적"의 기술적 토대입니다.

품질 플래그도 중요합니다.

플래그	뜻	건수
confidence_score	표적 지정 신뢰도 (9가 최고)	9점 1,972 assay / 8점 453 assay
data_validity_comment: Outside typical range	비정상적으로 크거나 작은 값	445
data_validity_comment: Potential transcription error	전사 오류 의심	65
potential_duplicate	중복 입력 의심	2,744
pchembl_value	ChEMBL이 계산한 pIC50	19,378 / 26,600

pchembl_value가 7,222건에 없는 이유 중 하나가 부등호 관측입니다. ChEMBL도 부등호 값에는 pChEMBL을 매기지 않습니다.

1.8 신약개발 맥락 — 22건이 어디서 왔는가

의약화학 논문의 전형적 흐름입니다.

1. 선별(screening): 수백~수천 화합물을 단일 농도에서 시험
2. 히트 확정: 억제율이 기준을 넘는 것만 농도-반응 곡선 측정 → IC50
3. 리드 최적화: 구조를 조금씩 바꿔가며 활성·선택성·물성 개선
4. 세포 실험 → 동물 → 임상

이 프로젝트가 쓴 22건은 2단계의 결과입니다. configs/cohort_scope_review.json에 기록했듯, 후보로 검토한 자료 중 하나는 "10 μ M에서 억제율 90% 초과인 화합물만 6점 농도반응 IC50 측정으로 진행"하는 선별이었습니다.

이것이 선택 편향입니다. 활성이 좋은 것만 IC50이 측정되므로, 라벨 분포가 좁고 높은 쪽에 몰립니다. 이 프로젝트의 22건도 pIC50 6.85~8.49(폭 1.65)에 모여 있습니다. 모델이 배울 변동폭 자체가 작습니다.

1.9 logP와 logD — M3에서 다룬 물성

M3에서 재현한 공개 벤치마크는 활성이 아니라 분배계수였습니다.

지표	정의	주의
logP	중성 분자의 옥탄올/물 분배계수	pH와 무관한 중성 종의 값
logD	특정 pH에서의 분배계수	이온화를 포함, pH 명시 필요

측정법도 다릅니다. shake-flask(흔들어 분배시킨 뒤 양쪽 농도 측정)와 전위차 적정(potentiometric titration)이 다른 값을 줄 수 있습니다. SAMPL 챌린지는 물-옥탄올 logP 예측을 겨루는 공개 대회입니다.

logP는 약물 유사성 지표(흡수·투과·대사)의 핵심이며, ADME(흡수·분포·대사·배설)의 "A"와 직결됩니다.

1.10 분해제(degrader) 지표 — M4의 맥락

C797S 같은 내성 변이에는 저해제 대신 표적 단백질 분해 전략이 쓰입니다. PROTAC(proteolysis targeting chimera)은 표적과 E3 리가아제를 동시에 붙잡아 표적을 분해시킵니다.

지표	뜻
DC50	표적을 50% 분해하는 농도
Dmax	달성 가능한 최대 분해율

IC50과 DC50은 완전히 다른 양입니다. IC50은 활성 억제, DC50은 단백질 양의 감소입니다. 섞어서 한 모델에 넣을 수 없습니다. 이 프로젝트는 pool_inhibition_and_degradation_labels: false로 고정했습니다.

M4(기업 문헌 사례)가 이 영역이었고, 원문을 확보하지 못해 보류했습니다.

2부. AI·기술 지식

2.1 분자를 컴퓨터에 넣는 방법

표현	성격	용도
SMILES	분자를 문자열로	입력 형식. 같은 분자에 여러 표기 가능
canonical SMILES	정규화된 하나의 표기	중복 확인
InChIKey	27자 해시	정확한 동일성 비교
Murcko scaffold	고리와 연결부만 남긴 골격	계열 구분, 분할
Morgan fingerprint	부분구조 존재를 비트로	모델 입력 벡터

Morgan fingerprint(ECFP와 유사)는 각 원자 주변을 반지름 r까지 훑어 부분구조를 해시해 고정 길이 비트벡터로 만듭니다. 이 프로젝트는 r=2, 2048비트, 입체화학 포함으로 고정했습니다.

`python

gen = rdFingerprintGenerator.GetMorganGenerator(radius=2, fpSize=2048, includeChirality=True)

`

실제로 겪은 함정: 빈 문자열 ""을 RDKit에 넣으면 None이 아니라 원자 0개 분자로 파싱됩니다. 그 상태로 fingerprint를 만들면 전부 0인 벡터가 나오고, 모델은 아무렇지 않게 예측값을 돌려줍니다. 실제로 빈 SMILES에 pIC50 8.057이 나왔습니다. 그래서 명시적으로 막았습니다.

```python
if not smiles or not smiles.strip():
    return None, None
mol = Chem.MolFromSmiles(smiles)
if mol is None or mol.GetNumAtoms() == 0:
    return None, None
```

이 결함은 LLM이 예상 밖 입력을 보내준 덕에 발견됐습니다. 규칙 기반 테스트로는 드러나지 않았습니다.

2.2 Tanimoto 유사도와 적용 범위

두 fingerprint의 유사도는 Tanimoto 계수로 잽니다.

$$T(A, B) = |A \cap B| / |A \cup B|$$

0이면 공통 부분구조가 없고, 1이면 같습니다. 0.85 이상을 "유사"로 보는 관행이 있지만 데이터셋에 따라 다릅니다.

적용 범위(applicability domain)는 모델의 예측을 믿을 수 있는 입력 영역입니다. 이 프로젝트는 세 기준을 썼습니다.

1. 질의 분자의 Murcko scaffold가 학습 12개 안에 있는가
2. 학습 분자와의 최대 Tanimoto가 0.5 이상인가
3. 예측값이 학습 라벨 범위(6.85~8.49) 안인가

이것이 왜 필수인지 실제로 확인했습니다. 구조가 전혀 다른 분자 10개를 넣어봤습니다.

분자	예측 pIC50	환산 IC50	최대 Tanimoto
포도당	8.048	약 9 nM	0.045
에탄올	8.054	약 9 nM	0.053
벤젠	8.055	약 9 nM	0.028
아스피린	8.055	약 9 nM	0.133
카페인	8.057	약 9 nM	0.110
니코틴	8.143	약 7 nM	0.163

예측값 폭이 0.095, 표준편차 0.035입니다. 학습 라벨 표준편차 0.381의 9%입니다.

적용 범위 밖에서 이 모델은 입력에 거의 반응하지 않습니다. 숫자만 돌려주는 API였다면 포도당이 9 nM EGFR 저해제로 보고됐을 것입니다. 그래서 서비스 응답에서 적용 범위 판정과 고지를 생략할 수 없게 설계했습니다.

2.3 분할 전략 — random과 scaffold는 다른 질문이다

분할	방법	답하는 질문
random	측정을 무작위로 나눔	같은 계열의 비슷한 분자를 맞출 수 있나
scaffold	같은 골격을 한 쪽에만	새로운 계열로 일반화되나

신약개발에서 중요한 것은 두 번째입니다. 이미 아는 계열의 변형체를 맞추는 것보다, 본 적 없는 골격을 평가하는 능력이 가치 있습니다.

scaffold 분할이 훨씬 어렵고 점수가 낮게 나옵니다. 그래서 random 분할 점수만 보고하면 성능을 과장하게 됩니다.

이 프로젝트에서 실제로 결론이 갈렸습니다.

분할	seed	RF-Dummy MAE 차이	95% 구간	판정
scaffold	42	-0.0146	-0.0819 ~ +0.0506	0 포함 — 미확정
scaffold	123	-0.0095	-0.0766 ~ +0.0639	0 포함 — 미확정
scaffold	2026	-0.0170	-0.0906 ~ +0.0513	0 포함 — 미확정
random	42	-0.0525	-0.1143 ~ -0.0047	0 제외 — 차이 있음
random	123	-0.0472	-0.1083 ~ +0.0111	0 포함
random	2026	-0.0437	-0.1118 ~ +0.0068	0 포함

random 분할 seed 42만 보면 "RF가 유의하게 낫다"고 쓸 수 있습니다. 주 지표인 scaffold 분할에서는 세 seed 모두 미확정입니다. 어느 쪽을 주 지표로 먼저 정해두지 않으면 결과를 보고 유리한 쪽을 고르게 됩니다.

2.4 데이터 누출과 GroupKFold

누출(leakage)은 테스트 정보가 학습에 새는 것입니다. 분자 데이터에서 흔한 형태들입니다.

- 같은 분자가 학습과 테스트에 동시에 (중복, 염 형태, 입체이성질체)
- 같은 scaffold가 양쪽에 (계열 정보 누출)
- 같은 문헌·같은 assay의 측정이 양쪽에 (조건 정보 누출)

scikit-learn의 GroupKFold는 그룹이 폴드를 넘지 않게 나눕니다. 이 프로젝트는 scaffold를 그룹으로 썼습니다. 입체이성질체는 누출 검사에서 한 그룹으로 묶었습니다(group_stereo_variants_together_for_leakage_checks: true).

2.5 기준 모델 — Dummy가 가장 중요한 모델이다

DummyRegressor(strategy="mean")는 항상 학습 데이터의 평균을 돌려줍니다. 입력을 전혀 보지 않습니다.

이것이 바닥선입니다. 복잡한 모델이 Dummy를 이기지 못하면 그 모델은 아무것도 배우지 못한 것입니다.

이 프로젝트의 scaffold 분할 MAE입니다.

모델	MAE (seed 42 / 123 / 2026)
Dummy	0.3096 / 0.3096 / 0.3096
RandomForest	0.2950 / 0.3001 / 0.2925
D-MPNN	0.3090 ~ 0.3111

RF가 약간 낮지만 신뢰구간이 0을 포함합니다. D-MPNN은 Dummy와 거의 같습니다. 22건으로는 어떤 모델도 평균 예측을 확실히 넘지 못했습니다.

Dummy의 Spearman이 음수(-0.101)인 것도 의미 있습니다. 상수를 예측하면 순위 상관이 정의되지 않거나 잡음이 됩니다.

2.6 D-MPNN — 분자 그래프 신경망

D-MPNN(Directed Message Passing Neural Network)은 분자를 그래프로 보고 표현을 학습합니다.

`

원자 = node, 결합 = edge

→ 방향성 결합 메시지 전달 (depth 단계 반복)

→ 분자 전체 표현으로 집계 (readout)

→ 회귀 출력 (feed-forward)

`

Morgan fingerprint는 사람이 정한 규칙으로 부분구조를 센 것이고, D-MPNN은 데이터에서 표현을 학습합니다. 데이터가 충분하면 후자가 유리하다고 보고됩니다.

이 프로젝트에서는 유리하지 않았습니다. paired 비교 12개 중 11개의 신뢰구간이 0을 포함했습니다. 원인을 분석했더니 예측값의 표준편차가 0.011~0.036이었습니다. 관측 라벨의 표준편차는 0.377입니다.

상수 붕괴(constant collapse)입니다. 표본이 너무 적어 모델이 "평균을 내놓는 것이 가장 안전하다"는 해로 수렴했습니다. 흥미롭게도 M6에서 RandomForest도 적용 범위 밖에서 같은 현상을 보였습니다(2.2절). 모델 종류의 문제가 아니라 22건·12 scaffold라는 규모가 의심됩니다.

구현에서 겪은 함정: Chemprop v1의 --seed는 데이터 분할 시드이고 모델 초기화 시드가 아닙니다. 모델 쪽은 --pytorch_seed(기본 0)입니다. 이걸 모르고 --seed만 바꿨을 때 seed 간 예측 차이가 7.2e-05였습니다. --pytorch_seed를 제대로 전달하자 4.0e-02로 늘었습니다. "seed를 바꿨는데 결과가 거의 같다"는 것은 seed가 적용되지 않았다는 신호입니다.

2.7 통계 — 신뢰구간이 0을 포함한다는 말의 뜻

평가 지표들입니다.

지표	성격	주의
MAE	평균 절대 오차	해석이 직관적, 이상치에 둔감
RMSE	제곱평균제곱근 오차	큰 오차에 민감
Spearman	순위 상관	값보다 순서가 중요할 때

점수 하나만 보면 "RF 0.295 〈 Dummy 0.310이니 RF가 낫다"가 됩니다. 하지만 표본이 22건입니다. 다른 22건을 뽑으면 순서가 바뀔 수 있습니다.

부트스트랩은 가진 데이터에서 복원추출로 가상의 재표본을 만들어 지표의 변동폭을 추정합니다. 이 프로젝트는 2000회, scaffold 단위로 재표집했습니다. 분자 단위가 아니라 scaffold 단위인 이유는 같은 골격의 분자들이 독립이 아니기 때문입니다.

paired 비교는 같은 테스트 분자에 대한 두 모델의 오차 차이를 봅니다. 모델별 점수를 따로 비교하는 것보다 검정력이 높습니다.

그 차이의 95% 구간이 0을 포함하면:

> 이 데이터로는 두 모델의 차이를 확정할 수 없다.

"차이가 없다"는 증명이 아닙니다. "있는지 없는지 이 표본으로는 말할 수 없다"입니다. 이 구분이 중요합니다. 전자는 강한 주장이고, 후자는 불확실성의 정직한 보고입니다.

2.8 재현성 — 해시, 버전, 사전 등록

이 프로젝트가 쓴 장치들입니다.

장치	방법	막는 문제
설정 고정	실행 전에 JSON으로 동결, SHA-256 기록	결과를 보고 기준을 고치는 것
데이터 해시	코호트 파일 SHA-256	다른 데이터로 바뀐 것을 모르는 것
모델 해시	joblib 파일 SHA-256	다른 모델이 서비스되는 것
버전 폴더	기존 출력 덮어쓰기 거부	이전 결과가 사라지는 것
의존성 고정	해시 lock, 컨테이너 내부 freeze	"내 기계에서는 됐는데"
베이스 이미지 digest	태그가 아닌 digest로 고정	같은 태그의 내용이 바뀌는 것
독립 검산	별도 스크립트로 지표 재계산	계산 코드 자체의 오류

사전 등록(pre-registration)이 특히 중요합니다. 측정 전에 예상을 적어두고, 결과를 본 뒤 그 예상을 고치지 않습니다.

M6에서 실제로 적어둔 예상과 결과입니다.

항목	사전 예상	실제	판정
호스트 p50	5~30 ms	9.348 ms	맞음
컨테이너 p50	10~60 ms	11.610 ms	맞음
컨테이너 모델 로딩	1~5 초	0.844 초	틀림
클라우드 콜드 스타트	2~15 초	0.13 초	틀림
클라우드 모델 로딩	0.5~3 초	4.998 초	틀림
이미지 push	3~20 분	약 1 분	틀림

7개 중 4개가 틀렸습니다. 고치지 않고 남겼습니다. 사전 예상이 틀린 기록은 실패가 아니라 그 예상 모델이 어디서 어긋났는지에 대한 정보입니다.

2.9 LLM Agent — 도구 호출과 평가

Agent는 LLM이 도구를 선택해 호출하고 결과를 바탕으로 답하는 구조입니다.

OpenAI function calling 규약: 모델이 tool_calls를 돌려주면, 각 호출의 결과를 role: "tool" 메시지로 tool_call_id와 함께 되돌려야 합니다.

실제로 겪은 오류: 도구 결과를 user 메시지로 전달했습니다. 그러자 모델이 자기가 이미 호출한 것을 보지 못하고 같은 호출을 6번 반복해 예산을 소진했습니다. 규약을 지키자 해결됐습니다.

Agent를 어떻게 평가하나 — 이 프로젝트는 6개 축을 정의했습니다.

축	질문
도구 선택	기대한 도구를 부르고 금지한 도구를 피했나
주장별 인용	수치를 담은 모든 주장에 출처가 붙었나
정보 부족 선언	근거가 없을 때 모른다고 했나. 있을 때 불필요하게 포기하지 않았나
오류 처리	도구 실패를 수치 날조 없이 처리했나
종료	호출 예산 안에서 끝냈나
필수 고지	요구한 고지 문구를 답변에 넣었나

final 8문항 결과입니다.

정책	전 축 통과	약점
규칙 기반	8/8	—
gpt-4.1	5/8	종료 6/8, 정보 부족 6/8
gpt-5-mini	4/8	종료 4/8

도구 선택·인용·오류 처리는 두 모델 모두 8/8이었습니다. 약점이 "언제 멈출지"에 몰렸습니다. 도구 범위 밖 질문(임상 3상 생존기간)에 gpt-4.1은 결론은 맞게 냈지만 5번 호출했고, 규칙 기반은 0번으로 끝냈습니다. 능력보다 절제의 문제입니다.

출처 검증 장치: 답변의 모든 숫자가 도구가 돌려준 값에 있는지 정규식으로 검사했습니다.

`python

NUMBER = re.compile(r"(?<![A-Za-z])(?<![0-9.])\d+(?:\.\d+)?(?![0-9.])(?![A-Za-z])")

`

IC50의 50이나 C797S의 797을 측정값으로 세지 않도록 앞뒤 문자를 봅니다. 이 장치가 실제로 작동했습니다 — gpt-4.1이 도구가 준 8.055를 8.06으로 반올림해 적었고, 검증이 답변을 반려했습니다. 날조는 아니지만, 답변의 숫자가 도구의 숫자와 다르면 원 출처로 되짚을 수 없습니다.

평가 설계의 함정: 개발용 질문(dev)으로 정책을 고치고, 최종 질문(final)은 한 번만 돌려야 합니다. gpt-4.1은 dev 6/6이었지만 final 5/8이었습니다. dev 점수를 성능으로 보고하면 과대평가입니다.

그리고 이 프로젝트는 "규칙 기반이 LLM보다 낫다"고 결론 내리지 않았습니다. 질문 14개를 규칙 정책 설계자와 같은 사람이 만들었고, 규칙 정책은 도구 4개 밖으로 나갈 수 없으며(LLM은 aspirin → CHEMBL25 해석을 해냈습니다), 표본이 8문항입니다. 자기가 만든 시험에서 자기 정책이 이긴 것을 일반화하지 않는다는 것이 결론입니다.

2.10 추론 서비스 — API 설계의 책임

FastAPI로 만든 엔드포인트입니다.

`

GET /healthz 프로세스 생존

GET /readyz 모델 로딩 + 해시 3개 일치 시 200, 아니면 503

GET /model-info 모델·코호트·설정 해시, 학습 규모, 라벨 범위, 고지, 런타임 버전

POST /predict SMILES 배열 → 분자별 예측·적용 범위 판정·고지

`

healthz와 readyz를 나눈 이유: 프로세스가 살아 있는 것과 모델이 제대로 로딩된 것은 다릅니다. 해시가 설정과 어긋나면 readyz가 503을 돌려줍니다. 다른 모델을 조용히 서비스하는 쪽이 멈추는 쪽보다 나쁩니다.

설계상 거부한 것들입니다.

- 학습·재학습 엔드포인트 없음 — 서비스는 추론만 한다
- 고지 생략 옵션 없음 — 2.2절의 상수 붕괴가 이유다
- 해석 불가 SMILES에 predicted_pIC50 필드 자체를 넣지 않음 — 0이나 평균값으로 메우지 않는다
- 예측값을 measured나 실측으로 부르는 필드명 없음

응답은 value_is_a_prediction_not_a_measurement: true를 스스로 달고 나옵니다.

2.11 컨테이너와 재현성

멀티플랫폼 이미지: Docker 이미지는 플랫폼별로 다릅니다. manifest 인덱스(여러 플랫폼을 묶은 목록)의 digest를 FROM에 쓰면 --platform 플래그로 플랫폼을 고를 수 있습니다.

`dockerfile

FROM python:3.12.14-slim-bookworm@sha256:392307d2...3564e

`

태그(:3.12.14-slim-bookworm)는 같은 이름으로 내용이 바뀔 수 있습니다. digest로 고정해야 "다시 만들 수 있다"가 성립합니다.

이미지 크기의 두 가지 의미를 실제로 혼동했습니다.

측정	arm64	amd64
압축 해제 (docker images)	829 MB	805 MB
압축 (레지스트리 저장)	—	173.6 MB

docker image inspect --format '{{.Size}}'가 173,608,921을 돌려줘 처음에 오해했습니다. Artifact Registry의 저장 크기가 정확히 173.612MB로 찍혀 그것이 압축된 레이어 크기임이 드러났습니다.

빌드 컨텍스트: .dockerignore를 허용 목록 방식으로 썼습니다 — 전부 제외하고 필요한 것만 되돌립니다.

`

*

!deployment/requirements-serve.txt

!src/egfr_lab/serving

...

`

거부 목록이면 새 폴더가 생길 때마다 빌드 컨텍스트에 조용히 섞입니다. 이 저장소는 공개이고 data/에 원자료 247MB가 있어, 빠뜨리는 쪽이 더 위험합니다.

2.12 클라우드 실행 — 측정 방법론이 결론을 바꾼다

Cloud Run에 배포해 실측한 결과입니다.

환경	서버 처리 p50	비고
로컬 호스트 (macOS arm64)	8.426 ms	
로컬 컨테이너 (linux/arm64)	10.040 ms	1.19배
Cloud Run (linux/amd64)	35.042 ms	4.2배

모델 로딩은 0.844초 → 4.998초로 5.9배 느려졌습니다.

런타임을 확인하니 Linux-4.19.0-gvisor-x86_64였습니다. Cloud Run은 gVisor 샌드박스에서 돕니다 — syscall을 사용자 공간에서 가로채므로 I/O가 많은 작업에 비용이 큽니다.

원인을 gVisor 하나로 단정하지 않았습니다. CPU 세대·클럭, 플랫폼(arm64→amd64), 샌드박스가 섞여 있고 분리 측정하지 않았습니다. 말할 수 있는 것은 "같은 코드·같은 모델·같은 라이브러리 버전으로 클라우드가 3.5~5.9배 느렸다"입니다.

측정에서 반드시 분리해야 하는 것이 있습니다.

측정	p50	포함하는 것
클라이언트 왕복	50.019 ms	네트워크 + TLS + 프런트엔드 + 서버
서버 처리	35.042 ms	서버만 (X-Process-Time-Ms 헤더)
차이	14.977 ms	네트워크와 프런트엔드

왕복 시간을 서버 성능으로 쓰면 틀립니다. 약 15 ms가 네트워크입니다.

콜드 스타트도 두 값이 다릅니다. 첫 요청 왕복은 135 ms인데 모델 로딩은 4.998초였습니다. 모순이 아닙니다 — Cloud Run이 시작 프로브로 컨테이너를 먼저 준비시킨 뒤 트래픽을 넘기기 때문에, 요청 왕복에 로딩 시간이 포함되지 않습니다. 클라이언트 체감 콜드 스타트와 컨테이너 실제 시작 비용은 다른 값입니다.

2.13 비용 — 요율을 손으로 적지 않는다

AWS 단계에서는 공개 가격 API에서 요율을 받아 응답 SHA-256과 함께 보존했습니다.

`

https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/AmazonECS/current/ap-northeast-2/index.json

`

블로그나 요약글의 수치는 리전과 시점이 어긋나기 쉽습니다. 서울 리전 Fargate ARM 요율은 vCPU·시간당 $0.03725, 메모리 GB·시간당 $0.00409였습니다(가격표 발행일 2026-10-19).

GCP는 가격 페이지 본문을 기계적으로 받지 못해(JS 렌더링) 무료 등급 수치를 2차 출처에 의존했습니다. 두 단계의 증거 수준이 다르다는 것을 보고서에 밝혔습니다.

과금 반영 지연: 측정과 같은 날 비용 화면에서 $0을 봐도 "과금 없음"과 "아직 미반영"을 구분할 수 없습니다. 구분하는 방법은 비용 테이블에 해당 서비스 행이 나타나는지 보는 것입니다.

2.14 겪은 함정 모음 — 디버깅에서 배운 것

증상	원인	교훈
계산은 끝났는데 프로세스가 2시간 멈춤	chemprop 워커가 종료되지 않음 (os_waitpid 블록)	sample 〈pid〉로 네이티브 스택을 봤다. 워커 8 → 0으로 바꾸니 7배 빨라졌다
127.0.0.1:8000이 다른 서비스를 응답	다른 프로세스가 IPv4로 포트 점유, Docker는 IPv6로 바인딩	엉뚱한 대상을 측정할 뻔했다. 측정 전에 /model-info 해시로 대상을 확인하게 했다
파일 행 수가 1 적게 셈	파일 끝 개행이 없어 wc -l이 덜 셈	설정 파일을 고치면 config_sha256 검증이 깨지므로 보고서에 정정했다
빈 SMILES에 예측값	RDKit이 빈 문자열을 원자 0개 분자로 파싱	LLM이 예상 밖 입력을 보내 발견했다
seed를 바꿨는데 결과가 같음	chemprop v1의 --seed는 분할 시드	--pytorch_seed가 모델 시드다
PDF 렌더러 크래시	함수 파라미터 header와 표 파싱 지역변수 header 충돌	이름을 분리했다
줄바꿈 걸친 굵게가 별표로 출력	렌더러가 줄 단위로 처리	원고에서 한 줄로 유지하고 렌더러에 경고를 넣었다

3부. 더 공부하면 좋을 것

이 프로젝트에서 다루지 않았거나 막힌 영역입니다. 다음 단계의 후보입니다.

주제	왜 필요한가
중도절단 회귀	부등호 관측 5,482건을 버리지 않고 쓰는 방법
다중작업 학습	변이별·실험별 데이터를 함께 쓰면서 섞지 않는 방법
예측 구간 보정	점 추정이 아니라 "얼마나 모르는지"를 함께 내놓기
사전학습 분자 모델	22건 같은 소표본에서 전이학습의 효과
활성 학습	다음에 어떤 화합물을 측정하면 정보가 가장 큰가
Cheng-Prusoff 보정	ATP 농도가 다른 IC50을 조건부로 비교하는 방법
구조 기반 방법	도킹·자유에너지 계산 (이 프로젝트 범위 밖)
MLOps	모델 레지스트리, 데이터 드리프트 감시, A/B 배포

그리고 이 프로젝트의 근본 제약은 하나입니다.

> 22건·12 scaffold로는 어떤 모델도 평균 예측을 확실히 넘지 못한다.

이를 풀려면 표본을 늘려야 하고, 그러려면 실험 조건이 같다는 것을 원문으로 확인해야 합니다. 선정 기준을 통과한 5,511건·558 assay가 대기 중이지만, 조건 동일성 확인이 막혀 있습니다. 데이터가 없어서가 아니라 근거가 없어서 쓰지 않았습니다.

참고 출처

- EGFR 변이와 저해제 세대: NCBI Bookshelf 키나아제 저해제 안내
- ChEMBL 데이터 해석: ChEMBL 공식 FAQ

- ChEMBL 접근 방법: EMBL-EBI 교육 자료
- D-MPNN 원 논문: Yang et al., 2019
- Chemprop v1: Heid et al., 2024
- Chemprop v2: Graff et al.
- RDKit 입문: 공식 문서
- 교차검증과 평가: scikit-learn 문서
- 부트스트랩: SciPy bootstrap
- assay 중복과 비교 가능성: Landrum & Riniker, 2024
- 데이터셋 품질: Papyrus
- Cloud Run: 공식 문서
- AWS Fargate: 공식 문서