EGFR Evidence Lab — 정의와 결과

이 문서는 세 가지를 적습니다. 무엇을 확인하려 했는가, 무엇을 미리 정의했는가, 무엇이 확인됐는가.

모든 수치는 저장소의 실제 산출물에서 왔습니다. 각 절 끝에 출처 경로를 적었습니다.

작성 2026-10-22 · 전체 테스트 81개 통과

1. 프로젝트의 정의

1.1 한 문장

> ChEMBL의 공개 EGFR 실험 데이터로 화합물 활성을 예측하고, 그 예측의 근거와 한계를 추적 가능하게 기록하는 프로젝트.

1.2 무엇이 목표가 아니었는가

이것을 먼저 적는 이유는, 목표를 좁게 정의하지 않으면 결과를 넓게 주장하게 되기 때문입니다.

목표가 아니다	이유
최고 성능 모델 만들기	데이터가 그것을 허용하지 않는다는 것이 결론 중 하나다
신약 후보 발굴	실험 검증 없는 예측은 후보가 아니다
EGFR 활성 예측 서비스	학습 범위가 22건·12 scaffold다
논문 성능 재현	축소 조건으로 돌렸으므로 동일 조건 재현이 아니다
LLM과 규칙 기반의 우열 판정	자기가 만든 시험으로 판정할 수 없다

1.3 확인하려 한 질문 6개

각 마일스톤은 하나의 질문에 대응합니다.

단계	질문
M1	공개 데이터로 만든 기준 모델이 평균 예측보다 나은가
M2	분자 그래프를 학습하는 D-MPNN이 수작업 fingerprint보다 나은가
M3	공개 논문의 벤치마크를 우리가 돌려도 비슷한 값이 나오는가
M4	기업이 보고한 EGFR 내성·분해제 사례를 원문 수준에서 검토할 수 있는가
M5	LLM이 도구를 골라 쓰면서 근거 없는 수치를 만들지 않는가
M6	이 모델을 버전이 고정된 서비스로 만들어 클라우드에서 실제로 돌릴 수 있는가

1.4 이 질문들이 공유하는 전제

모든 질문에 "확인할 수 없으면 확인할 수 없다고 적는다"는 조건이 붙었습니다. 그래서 결과의 절반이 "미확정"입니다. 그것이 실패가 아니라 이 프로젝트의 산출물입니다.

2. 실행 전에 정의한 것

결과를 본 뒤 기준을 고치는 것을 막기 위해, 각 단계의 설정을 실행 전에 JSON으로 동결하고 SHA-256을 기록했습니다.

2.1 데이터 선정 정책

configs/cohort_policy.json · configs/project.json

정의한 것	값
표적	CHEMBL203 (인간 EGFR)
지표	IC50 → pIC50 (등식 값만)
라벨 단위	nM 기준 환산
변이 정책	변이와 정상형을 섞지 않는다
모르는 변이	정상형으로 가정하지 않는다 (unknown_variant_is_wild_type: false)
실험 종류	생화학과 세포 실험을 섞지 않는다
지표 혼합	IC50·Ki·Kd를 섞지 않는다
억제·분해	억제 지표와 분해 지표를 섞지 않는다
원자료	원 응답과 제외 사유를 모두 보존한다

2.2 assay 병합(pooling) 조건

같은 표적의 다른 실험 결과를 합치려면 13개 필드가 모두 확인되고 같아야 한다고 정의했습니다.

`

species · variant · protein_construct · enzyme_concentration · atp_uM ·

substrate · substrate_concentration · preincubation_minutes ·

reaction_minutes · temperature_C · buffer_pH · readout · inhibitor_scope

`

추가 조건:

항목	기준	
값이 빠진 경우	같다고 보지 않는다	
공유 구조 최소 개수	5개	
일치 허용 오차	\	Δ pIC50\
일치 비율 최소	0.75 (Wilson 95% 하한도 0.75)	
중앙값 편향 한계	부트스트랩 95% 구간이 ±0.3 안	
\	Δ\	〉1 비율
묶음 내 모든 쌍	전부 통과해야 한다	

마지막 줄의 기준 상태도 적었습니다 — "프로젝트의 사전 고정 운영 기준이며 EGFR에서 검증된 보편적 합격선이 아니다."

2.3 평가 설계

항목	정의
주 분할	scaffold (Murcko 골격 단위)
보조 분할	random (분자 단위 그룹)
seed	42, 123, 2026
주 지표	MAE
보조 지표	RMSE, Spearman
부트스트랩	2000회, scaffold 단위 재표집
신뢰수준	95%
테스트셋 튜닝	금지 (test_used_for_tuning: false)

scaffold를 주 분할로 먼저 정한 것이 중요합니다. 나중에 보겠지만, random 분할만 보면 결론이 달라집니다.

2.4 Agent 사양

configs/agent_eval.json

항목	값
도구	4개 (예측·실측 조회·문헌 검색·근거 조회)
호출 예산	6회
검색 재시도	2회
출처 요구	필수
수치 날조	금지 (llm_may_invent_measurements: false)
질문 분리	개발용 6문항 / 최종 8문항
최종 실행	한 번만 돌리고 결과를 그대로 싣는다

정책 코드를 질문 파일보다 먼저 작성했다는 사실도 기록했습니다. 질문에 맞춰 정책을 쓰지 않았다는 증거입니다.

2.5 서비스 계약

configs/serving_m6.json

설계상 거부한 것을 명시했습니다.

- 학습·재학습 엔드포인트
- 고지 생략 옵션
- 변이형·세포 실험·분해제 지표 예측
- 예측값을 "측정값"으로 부르는 필드명

2.6 금지 목록

각 설정 파일에 forbidden 항목을 두었습니다. 실제로 적은 것들입니다.

- 최종 질문의 점수를 본 뒤 정책을 고치고 그것을 최초 결과처럼 쓰는 것
- 규칙 기반 정책의 결과를 "LLM Agent를 평가했다"고 쓰는 것
- 지연시간 측정을 보고 사전 예상을 고친 뒤 맞췄다고 쓰는 것
- 컨테이너 검증만 하고 "클라우드 배포 완료"라고 쓰는 것
- 과금 $0을 "비용을 측정했다"로 쓰는 것
- 무료 등급 수치를 1차 출처에서 확인했다고 쓰는 것

---

3. 데이터 — 26,600건이 22건이 된 과정

3.1 수집

ChEMBL REST API로 CHEMBL203의 IC50 측정을 전부 받았습니다.

항목	규모
측정	26,600건
분자	14,776개
assay	2,425개
문헌	1,299편 (1989~2025, DOI 1,197건)

출처: data/interim/chembl_full_20261020/

3.2 선정 기준을 순차 적용한 결과

단계	기준	남은 측정	분자	assay	문헌
0	수집 전체	26,600	14,776	2,425	1,298
1	인간	26,600	14,776	2,425	1,298
2	등식 값만	19,719	10,912	2,053	1,054
3	단위·값 확정	19,643	10,851	2,042	1,046
4	변이 미지정	15,377	10,072	1,460	990
5	생화학 실험	14,114	9,401	1,328	928
6	단일 단백질 형식	9,938	6,844	913	697
7	표적 신뢰도 9	6,503	4,939	649	513
8	품질 경고 없음	6,430	4,895	641	508
9	중복 표시 제외	5,511	4,722	558	461
10	단일 assay 선택	22	22	1	1

이것은 사후 재구성입니다. 실제 코호트 확정은 여러 단계의 수동 원문 검토를 거쳤고 이 필터 순서와 같지 않습니다.

3.3 가장 중요한 한 줄

> 선정 기준을 모두 통과한 측정이 5,511건, assay가 558개 남았는데, 학습에 쓴 것은 22건이다.

이유는 2.2절의 pooling 조건입니다. cross-assay pooling 승인 0쌍. 558개 assay 중 실험 조건이 같다는 것을 원문으로 확인한 조합이 하나도 없었습니다.

데이터가 없어서가 아니라 근거가 없어서 쓰지 않았습니다. 이것이 이 프로젝트의 가장 큰 제약이고, 가장 의도적인 선택입니다.

출처: scripts/build_portfolio_data.py (재현 가능)

---

4. 결과 — 질문별 답

4.1 M1 — 기준 모델이 평균 예측보다 나은가

답: 확정할 수 없다.

scaffold 분할(주 지표), 22건, seed 3개:

모델	MAE (42 / 123 / 2026)
Dummy (평균 예측)	0.3096 / 0.3096 / 0.3096
Morgan-RF	0.2950 / 0.3001 / 0.2925

RF가 약간 낮습니다. 그런데 차이의 95% 구간은:

seed	RF-Dummy	95% 구간	0 포함
42	-0.0146	-0.0819 ~ +0.0506	예
123	-0.0095	-0.0766 ~ +0.0639	예
2026	-0.0170	-0.0906 ~ +0.0513	예

세 seed 모두 구간이 0을 포함합니다. 이 데이터로는 우위를 확정할 수 없습니다.

분할 방식이 결론을 바꿉니다. random 분할 seed 42는 구간 상한이 -0.0047로 0을 넘지 않습니다. 주 지표를 먼저 scaffold로 정해두지 않았다면 유리한 쪽을 고를 수 있었습니다.

출처: reports/baseline_pilot_20261020_v2/

4.2 M2 — D-MPNN이 fingerprint보다 나은가

답: 구별되지 않는다.

모델	scaffold MAE
Dummy	0.3096
D-MPNN	0.3090 ~ 0.3111
Morgan-RF	0.2925 ~ 0.3001

paired 비교 12개 중 11개의 95% 구간이 0을 포함했습니다.

원인을 찾았습니다. D-MPNN 예측값의 표준편차가 0.011~0.036이었습니다. 관측 라벨의 표준편차는 0.377입니다. Spearman은 6개 설정 전부 음수였습니다.

상수 붕괴입니다. 모델이 입력을 보지 않고 평균 근처를 내놓는 해로 수렴했습니다.

구현에서 겪은 오류도 기록했습니다 — Chemprop v1의 --seed는 데이터 분할 시드이고 모델 시드는 --pytorch_seed입니다. 바로잡기 전 seed 간 예측 차이가 7.2e-05였고, 바로잡은 뒤 4.0e-02가 됐습니다.

출처: reports/dmpnn_pilot22_20261021_v2/

4.3 M3 — 공개 벤치마크를 재현할 수 있는가

답: 저자값과 구별되지 않는 결과가 나왔다. 단 동일 조건 재현은 아니다.

SAMPL 물-옥탄올 logP, RMSE:

세트	우리 측정	저자 보고	판정
SAMPL6	0.3666	0.27	저자값이 우리 95% 구간 안
SAMPL7	0.6843	0.49	저자값이 우리 95% 구간 안
SAMPL9	1.0530	1.11	저자값이 우리 95% 구간 안

세 세트 모두 저자 보고값이 우리 측정의 부트스트랩 95% 구간 안에 들어왔습니다. 구별되지 않는다는 뜻입니다.

동일 조건이 아닌 점을 명시했습니다 — 축소한 조건(에폭·앙상블 규모 등)으로 돌렸고, 저자 환경(Linux·NVIDIA·Python 3.7)과 다릅니다. 그래서 "재현했다"가 아니라 "축소 조건에서 구별되지 않는 결과를 얻었다"로 적었습니다.

실행 중 장애도 기록했습니다 — 계산이 끝났는데(Elapsed time = 1:58:48) 프로세스가 2시간 종료되지 않았습니다. sample 〈pid〉로 네이티브 스택을 떠서 워커 종료 대기를 확인했고, --num_workers 0으로 바꾸니 29초에 정상 종료됐습니다.

출처: reports/sampl_repro_20261021_v2/

4.4 M4 — 기업 문헌 사례를 검토할 수 있는가

답: 할 수 없다. 원문이 유료다.

대상 DOI 10.1002/ardp.70193의 접근성을 다섯 경로로 확인했습니다.

경로	결과
Crossref	vor / tdm
OpenAlex	closed
Europe PMC	"Subscription required"
Semantic Scholar	CLOSED
PubMed LinkOut	일치

Wiley의 403은 Cloudflare 봇 차단이며 유료화의 증거가 아니라고 구분했습니다. 대체 경로도 확인했습니다 — 프리프린트 없음, 관련 특허 2건은 약물설계 방법이고 이 논문의 데이터가 아님, 기관 리포지터리는 미확인.

유료 콘텐츠를 우회하지 않았습니다. API 응답 5개를 보존하고 SHA-256을 전부 검증해 차단 증거로 남겼습니다.

출처: data/raw/m4_access_evidence_20261021/manifest.json

4.5 M5 — LLM이 근거 없는 수치를 만들지 않는가

답: 도구 선택·인용·오류 처리는 통과했다. 약점은 언제 멈출지였다.

final 8문항, 6개 축:

축	규칙 기반	gpt-4.1	gpt-5-mini
도구 선택	8/8	8/8	8/8
주장별 인용	8/8	8/8	8/8
오류 처리	8/8	8/8	8/8
정보 부족 선언	8/8	6/8	8/8
필수 고지	8/8	7/8	7/8
종료	8/8	6/8	4/8
전 축 통과	8/8	5/8	4/8

출처 검증 장치가 실제로 작동했습니다. gpt-4.1이 도구가 준 8.055를 8.06으로 적어 답변이 반려됐습니다. 정확히 말하면 날조가 아니라 반올림입니다. 없는 값을 만든 게 아니라 있는 값을 변형했습니다. 그래도 답변의 숫자가 도구의 숫자와 다르면 원 출처로 되짚을 수 없어 막았습니다.

이 건을 고치지 않았습니다. 검증 규칙을 느슨하게 하면 final 점수를 사후 조작하는 것이 됩니다.

일반화하지 않습니다. 질문 14개를 규칙 정책 설계자와 같은 사람이 만들었고, 규칙 정책은 도구 4개 밖으로 나갈 수 없으며(LLM은 aspirin → CHEMBL25 해석을 해냈습니다), 표본이 8문항입니다.

dev가 final을 과대평가했습니다. gpt-4.1은 dev 6/6 → final 5/8이었습니다.

개발 중 발견한 내 결함 3건도 기록했습니다.

증상	성격
빈 SMILES에 pIC50 8.057	내 도구 버그. 규칙 정책으로는 드러낼 수 없었고 LLM이 발견했다
같은 호출 6회 반복	내 프로토콜 오류. OpenAI tool_calls 규약 미준수
D6 오답 처리	내 평가 기준 오류. 규칙 정책의 한계를 정답으로 굳혔다

출처: reports/agent_eval_20261021_final_openai/

4.6 M6 — 서비스로 만들어 클라우드에서 돌릴 수 있는가

답: 할 수 있다. 다만 모델의 한계가 서비스에서 더 뚜렷해졌다.

컨테이너 검증:

항목	결과
호스트/컨테이너 예측 동일성	통과 — probe 5개 소수 3자리까지 일치
모델 해시 3개 일치	통과 (양쪽)
재시작 후 재로딩	통과 — 2회 모두
오류 처리 10건	통과 — 10/10 (양쪽)
로그와 SMILES 미유출	통과 — 256줄, 유출 0건

클라우드 실행 (Google Cloud Run, 서울 리전, 요청 241건):

항목	결과
로컬과 예측 일치	5/5 완전 일치
모델 해시 3개	일치
오류 처리 10건	10/10
로그	101줄, SMILES 유출 0건

AWS가 먼저 막혔습니다. 비용 추정까지 1차 출처(공개 가격 API)로 끝냈는데 aws login 승인 단계에서 계정 수준 제한이 떴습니다. 자원을 하나도 만들지 않고 Cloud Run으로 전환했습니다.

가장 중요한 발견: 적용 범위 밖에서 모델이 사실상 상수를 돌려줍니다. 구조가 전혀 다른 분자 10개의 예측값이 8.048~8.143(폭 0.095)에 모였고, 예측 표준편차 0.035는 학습 라벨 표준편차 0.381의 9%입니다. 포도당이 pIC50 8.05(IC50 약 9 nM)로 나옵니다.

그래서 응답에서 적용 범위 판정과 고지를 생략할 수 없게 만들었습니다.

두 번째 발견: 같은 코드·같은 모델·같은 라이브러리 버전으로 클라우드가 3.5~5.9배 느렸습니다.

항목	로컬 컨테이너	Cloud Run	배수
모델 로딩	0.844초	4.998초	5.9배
서버 처리 p50	10.040 ms	35.042 ms	3.5배

런타임이 Linux-4.19.0-gvisor-x86_64였습니다. gVisor 샌드박스입니다. 원인을 그것 하나로 단정하지 않았습니다 — CPU·플랫폼·샌드박스가 섞여 있고 분리 측정하지 않았습니다.

출처: reports/serving_m6_20261021/ · reports/serving_m6_cloud_20261022/

---

5. 사전 예상과 실제

측정 전에 적어두고 비교했습니다. 결과를 보고 예상을 고치지 않았습니다.

5.1 M6 컨테이너

항목	예상	실제	판정
호스트 p50	5~30 ms	9.348 ms	범위 안
컨테이너 p50	10~60 ms	11.610 ms	범위 안
컨테이너가 더 느림	예상	1.24배	맞음
모델 로딩 (호스트)	1~5초	1.218초	범위 안
모델 로딩 (컨테이너)	1~5초	0.844초	틀림
예측 일치	일치 예상	일치	맞음
이미지 크기	600~1400 MB	829 MB	범위 안

5.2 M6 클라우드

항목	예상	실제	판정
로컬과 예측 일치	일치 예상	5/5 일치	맞음
서버 처리 p50	10~40 ms	35.042 ms	범위 안
왕복 p50	30~150 ms	50.019 ms	범위 안
콜드 스타트 첫 요청	2~15초	0.13초	틀림
클라우드 모델 로딩	0.5~3초	4.998초	틀림
이미지 push	3~20분	약 1분	틀림

5.3 왜 틀렸는가

항목	원인
콜드 스타트 0.13초	예상 모델 자체가 틀렸다. Cloud Run이 시작 프로브로 컨테이너를 먼저 준비시킨 뒤 트래픽을 넘긴다. 클라이언트 체감 콜드 스타트와 컨테이너 실제 시작 비용은 다른 값이다
모델 로딩 4.998초	gVisor 샌드박스 비용을 과소평가했다
push 약 1분	805 MB를 올린다고 가정했는데 레지스트리에 저장되는 것은 압축된 173.6 MB였다
컨테이너 로딩 0.844초	모델 파일이 324 KB인데 하한을 1초로 잡은 것이 느슨했다

사전 예상이 틀린 기록은 실패가 아닙니다. 그 예상이 어디서 어긋났는지에 대한 정보입니다.

---

6. 주장하지 않는 것

주장하지 않음	이유
"EGFR 활성 예측 서비스"	학습 범위가 22건·12 scaffold·단일 문헌·단일 assay의 정상형 생화학 IC50이다
"RF가 Dummy보다 낫다"	scaffold 분할 3 seed 모두 구간이 0을 포함한다
"D-MPNN을 평가했다"	22건 규모에서 상수로 붕괴했으므로 방법을 평가한 것이 아니다
"논문 성능을 재현했다"	축소 조건이다. 저자값과 구별되지 않는 결과를 얻었을 뿐이다
"LLM보다 규칙 기반이 낫다"	자기가 만든 8문항의 결과다
"비용을 측정했다"	과금 금액을 측정과 같은 날 봤고 미반영과 구분되지 않는다
클라우드가 느린 원인이 gVisor	분리 측정하지 않았다
지연시간이 처리량	순차 200회·배치 1·워커 1의 측정이다
변이형·세포 실험 예측 가능	학습 라벨이 정상형 생화학 IC50뿐이다

---

7. 완성된 것

구분	내용
데이터	ChEMBL EGFR 26,600건 수집, 원 응답·매니페스트·제외 사유 보존
정제	선정 정책 고정, 퍼널 재현 스크립트, pooling 조건 13필드
모델	Dummy·Morgan-RF·D-MPNN, scaffold/random 분할, 3 seed
통계	scaffold 단위 부트스트랩 2000회, paired 신뢰구간, 독립 검산
재현	SAMPL 축소 재현, 저자 자료 해시 보존, 장애 기록
Agent	도구 4개, 6축 평가, dev/final 분리, 출처 검증 정규식
서비스	FastAPI 추론 API, 해시 3개 검증, 적용 범위 판정 강제
컨테이너	digest 고정 이미지, non-root, 허용 목록 .dockerignore
클라우드	Cloud Run 실배포, 요청 241건, 측정 후 자원 삭제
화면	대시보드 2섹션 — 정제 퍼널·지표·근거 추적·적용 범위
테스트	81개 통과

8. 남은 것

8.0 정의했지만 실행하지 않은 것

이것을 먼저 적습니다. 설정 파일에 required로 적힌 것과 실제 산출물이 어긋나면 기록의 신뢰가 떨어집니다.

항목	어디에 정의	실행하지 않은 이유
학습곡선	cohort_policy.json의 learning_curve_and_scaffold_coverage_required: true	22건에서 샘플을 줄이면 scaffold 분할이 성립하지 않는다. 15건이면 scaffold 8~9개, 10건이면 5~6개, 5건이면 2~3개다. 이미 22건에서 구간이 0을 포함하므로 더 작은 표본에서는 곡선의 기울기 자체를 추정할 수 없다
scaffold 커버리지	같은 항목	규모와 무관하게 가능했고 새 정보를 줄 수 있었다. 미실행 이유는 우선순위 판단이며 불가능해서가 아니다
Chemprop v2	docs/03_tech_stack.md · pyproject.toml의 deep extra	M3 재현이 저자 환경의 v1.6.1을 요구했고, M2도 같은 환경으로 통일해 버전 차이가 결과에 섞이지 않게 했다. 문서를 2026-10-22에 정정했다
BM25·임베딩 문헌 검색	pyproject.toml의 literature·dense extra	정확한 식별자 조회로 충분했고 검색 품질을 평가할 질의 집합을 만들지 않았다
MLflow 상시 운영	tracking extra	JSON 매니페스트로 충분했다. 처음부터 "필요 시"로 적어 둔 항목이다
model card	관행	내용은 보고서와 manifest에 있으나 표준 형식으로 모으지 않았다

학습곡선을 기계적으로 실행하지 않은 판단 자체를 기록했습니다. 예상된 결과("전 구간에서 구별 불가")를 하나 더 추가하는 것보다, 실행이 무의미한 이유를 남기는 쪽을 택했습니다. 코호트가 늘어나면 이 판단은 무효입니다.

기록 위치: configs/cohort_policy.json의 learning_curve_decision_20261022 · configs/portfolio_scope.json의 defined_but_not_executed_20261022

src/egfr_lab의 evaluation·features·literature 패키지는 비어 있었고 docstring이 "Planned"로 남아 있었습니다. 세 기능이 실제로는 modeling·agent.tools·scripts에 구현돼 있어, 각 패키지에 구현 위치를 적었습니다.

8.1 외부 조건이 막은 것

과제	상태
M4 기업 문헌 사례	보류 — 원문 유료. 외부 조건이 바뀌어야 재개
코호트 확대 (furan45)	보류 — 방법론 원문 미확보, 프로토콜 5개 항목 미확인
코호트 확대 (patent64)	보류 — 구조 검증 0행, MS 불일치 13건
보류 목록 5건	CHEMBL2439336 · CHEMBL5638807/14/15 · CHEMBL5736995
과금 금액 확정	2026-10-23 이후 비용 테이블 재확인
M5 다음 반복	반올림 허용 여부, 종료 개선, 질문 집합을 다른 출처에서 작성

8.2 설계해 두었으나 새 마일스톤 규모인 것

부등호 관측 5,482건을 분류 과제로 쓰는 것입니다.

회귀는 assay 조건에 민감해서 pooling이 막혔습니다. 그런데 〉10000 nM(10 μM까지 올려도 50% 억제 없음)을 "비활성" 라벨로 쓰면, 조건 민감도가 훨씬 낮은 과제가 됩니다. ATP 농도가 1 μM이든 10 μM이든 10 μM에서 안 듣는 화합물은 강한 저해제가 아닙니다.

그러면 원문 검증 없이도 수천 건 규모를 쓸 수 있습니다. 22건 벽을 우회하는 유일한 경로로 보입니다.

단 이것도 가정입니다. "조건 민감도가 낮다"를 먼저 검증해야 합니다 — 같은 화합물이 여러 assay에서 활성/비활성으로 갈리는 비율을 재면 됩니다. 그 데이터는 이미 있습니다.

8.1 근본 제약 하나

> 22건·12 scaffold로는 어떤 모델도 평균 예측을 확실히 넘지 못한다.

M2의 D-MPNN 상수 붕괴와 M6의 RF 상수 붕괴가 같은 뿌리로 의심됩니다. 이를 풀려면 표본을 늘려야 하고, 그러려면 실험 조건 동일성을 원문으로 확인해야 합니다.

선정 기준을 통과한 5,511건·558 assay가 대기 중입니다. 데이터가 없어서가 아니라 근거가 없어서 쓰지 않았습니다. M4·furan45·patent64가 모두 같은 벽에 막혀 있습니다 — 유료 논문과 특허 원문입니다.

---

9. 이 프로젝트가 실제로 보여주는 것

모델 성능은 입증되지 않았습니다. 그런데 이 프로젝트가 보여주는 것은 다른 것입니다.

1. 공개 데이터의 함정을 실제로 밟고 기록했다 — 부등호 5,482건, 변이 미지정 115건, 품질 경고 510건, 중복 의심 2,744건, 조건 불일치로 pooling 0쌍

2. 결과를 과장하지 않는 장치를 만들고 지켰다 — 설정 사전 동결, 사전 예상 등록, 주 지표 우선 지정, 금지 목록, 독립 검산
3. 사전 예상이 틀린 것을 그대로 남겼다 — M6에서만 4건
4. 자기 결함을 기록했다 — Agent 개발 중 3건, M6에서 2건, 측정 대상 오인 1건
5. 막힌 것을 막혔다고 적었다 — M4, 코호트 확대 2건, 과금 금액
6. 예측값에 한계를 붙여야 하는 이유를 실증했다 — 적용 범위 밖 상수 붕괴
7. 정의했지만 실행하지 않은 것을 모아 적었다 — 6건. 그중 학습곡선은 실행이 무의미한 이유를, scaffold 커버리지는 "가능했지만 우선순위에서 밀렸다"를 구분해 기록했다

7번이 가장 불편한 항목입니다. 꼼꼼함을 내세우는 프로젝트에서 required: true와 실제가 어긋난 것을 발견했습니다. 지우는 대신 이유와 함께 남겼습니다.

면접에서 "왜 22건인가"를 물으면 답이 준비돼 있습니다. 5,511건이 기준을 통과했지만 조건 동일성을 원문으로 확인하지 못해 쓰지 않았습니다.

산출물 경로

단계	보고서
전체	configs/portfolio_scope.json · HANDOFF.txt
데이터	reports/data_audit_summary_ko.md · reports/cohort_scope_evidence_ko.md
M1	reports/baseline_pilot_20261020_v2/
M2	reports/dmpnn_pilot22_20261021_v2/
M3	reports/sampl_repro_20261021_v2/benchmark_repro_report_ko.md
M4	data/raw/m4_access_evidence_20261021/manifest.json
M5	reports/agent_eval_20261021_final_openai/agent_llm_report_ko.md
M6	reports/serving_m6_20261021/serving_report_ko.md · reports/serving_m6_cloud_20261022/cloud_report_ko.md
학습 가이드	docs/15_learning_guide_medical_ai_ko.md